

ESTADISTICA INFERENCIAL
PRACTICA CALIFICADA 5

Problema 1 (7 puntos)

En el sector de pequeñas empresas de mecánica automotriz, un economista distingue dos sub sectores: las dedicadas a pintar automóviles y las dedicadas a reparar automóviles (sin incluir pintado). El capital inicial en el primer caso es una v.a. $X \sim N(\mu_X, \sigma^2 = 4)$ y en el segundo es una v.a. $Y \sim N(\mu_Y, \sigma^2 = 4)$, siendo ambas v.a. independientes.

Una m.a. de 9 microempresarios del primer sub sector dio los capitales iniciales (en miles de US\$) (2, 4, 3, 3, 9, 9, 3, 4, 7) y una m.a. de 4 microempresarios del segundo sub sector fue (8, 7, 10, 9).

- Use la independencia de las m.a. para hallar los estimadores MV de μ_X y μ_Y y calcule los errores estándar e.e. correspondientes. Recuerde que en general, si $\hat{\theta}$ es estimador de θ , entonces su error estándar de estimación es e.e. $(\hat{\theta}) := \sqrt{V(\hat{\theta})}$. (2p.)
- Construya intervalos de confianza de 95% para μ_X y μ_Y y úselos para estudiar la afirmación: “Es más barato iniciarse en el sector de pintado de automóviles que en el de reparación de automóviles”. (2p.)
- Suponga ahora que la varianza común σ^2 es desconocida. Dada la independencia, se sabe que $f_{XY}(x, y) = f_X(x)f_Y(y)$. Con esta información estime los tres parámetros mediante máxima verosimilitud y vea si el estimador de σ^2 resulta insesgado. (3p.)

Solución:

- El estimador MV de μ_X** es simplemente el estimador usual de μ en una distribución normal, cosa que ya se vio en clase y en los apuntes de clase y que repetimos brevemente aquí:

$$f_X(x; \mu_X, \sigma_X^2 = 4) = \frac{e^{-\frac{(x-\mu_X)^2}{8}}}{\sqrt{2\pi}2} \Rightarrow L(\mu_X) = \prod_{j=1}^{n_X} f_{X_j}(x_j; \mu_X) = f_{X_1}(x_1; \mu_X) \times f_{X_2}(x_2; \mu_X) \times \dots \times f_{X_{n_X}}(x_{n_X}; \mu_X)$$

$$= \frac{e^{-\frac{(x_1-\mu_X)^2}{8}}}{\sqrt{2\pi}2} \times \frac{e^{-\frac{(x_2-\mu_X)^2}{8}}}{\sqrt{2\pi}2} \times \dots \times \frac{e^{-\frac{(x_{n_X}-\mu_X)^2}{8}}}{\sqrt{2\pi}2} = \frac{e^{-\sum_{j=1}^{n_X} \frac{(x_j-\mu_X)^2}{8}}}{(\sqrt{2\pi}2)^{n_X}}$$

es la función de verosimilitud de μ_X , es diferenciable y para maximizarla, es más sencillo trabajar con la log-verosimilitud $l(\mu_X) = \ln(L(\mu_X))$:

$$l(\mu_X) = \ln \left(\frac{e^{-\sum_{j=1}^{n_X} \frac{(x_j-\mu_X)^2}{8}}}{(\sqrt{2\pi}2)^{n_X}} \right) = -\sum_{j=1}^{n_X} \frac{(x_j - \mu_X)^2}{8} - \ln((\sqrt{2\pi}2)^{n_X}) \Rightarrow \frac{\partial l(\mu_X)}{\partial \mu_X} = -\frac{1}{8} \sum_{j=1}^{n_X} \frac{\partial (x_j - \mu_X)^2}{\partial \mu_X} =$$

$$-\frac{1}{8} \sum_{j=1}^{n_X} 2(x_j - \mu_X) \times -1 = 0 \Rightarrow \sum_{j=1}^{n_X} x_j - n_X \mu_X = 0 \Rightarrow n_X \bar{X} - n_X \mu_X = 0, \text{ de donde el estimador Máximo verosímil de } \mu_X \text{ es } \hat{\mu}_X = \bar{X}, \text{ asumiendo las condiciones de segundo orden para el máximo.}$$

análogamente, el estimador M.V. de μ_Y es $\hat{\mu}_Y = \bar{Y}$; además e.e. $(\bar{X}) = \sqrt{V(\bar{X})} = \sqrt{\frac{\sigma_X^2}{n_X}} = \sqrt{\frac{4}{9}} = \frac{2}{3} = 0.67$ y

$$e.e.(\bar{Y}) = \sqrt{\frac{\sigma_Y^2}{n_Y}} = \sqrt{\frac{4}{4}} = 1.$$

- Aquí hay que construir respectivos I.C. de 95% de confianza para μ_X y para μ_Y y ver si el I.C. de μ_X cae totalmente debajo o a la izquierda del I.C. para μ_Y ; de ser así, sí sería aceptable la afirmación, en caso contrario, sería al revés o en todo caso no se podría decir nada.

I.C. de 95% para μ_X :

Como $\bar{X} \sim N\left(\mu_X, \frac{\sigma_X^2}{n_X} = \frac{4}{9}\right) \Rightarrow Z = \frac{(\bar{X} - \mu_X)}{\sqrt{\frac{\sigma_X^2}{n_X}}} = \frac{3}{2}(\bar{X} - \mu_X) \sim N(0,1)$ es una buena variable base.

Planteamos valores a y b tales que $P(a \leq Z \leq b) = P\left(a \leq \frac{3}{2}(\bar{X} - \mu_X) \leq b\right) = 0.95$ con $P(Z \leq a) = P(Z \geq b) = 0.025$, de donde resulta $a = -1.96$; $b = 1.96$

$$0.95 = P\left(-1.96 \leq \frac{3}{2}(\bar{X} - \mu_X) \leq 1.96\right) = P\left(-1.96 \times \frac{2}{3} \leq (\bar{X} - \mu_X) \leq 1.96 \times \frac{2}{3}\right) =$$

$$P\left(-\bar{X} - 1.96 \times \frac{2}{3} \leq -\mu_X \leq -\bar{X} + 1.96 \times \frac{2}{3}\right) = P\left(\bar{X} - 1.96 \times \frac{2}{3} \leq \mu_X \leq \bar{X} + 1.96 \times \frac{2}{3}\right).$$

El I.C. de 95% para μ_X es $\bar{X} - 1.31 \leq \mu_X \leq \bar{X} + 1.31$; como la muestra es (2, 4, 3, 3, 9, 9, 3, 4, 7), calculamos $\bar{X} = \frac{\sum_{j=1}^n X_j}{n} = \frac{44}{9} = 4.89$ y el I.C. calculado es $4.89 - 1.31 \leq \mu_X \leq 4.89 + 1.31 \Rightarrow \mathbf{3.58 \leq \mu_X \leq 6.20}$ con **95% de confianza**.

I.C. de 95% para μ_Y : En este caso $\bar{Y} \sim N\left(\mu_Y, \frac{\sigma_Y^2}{n_Y} = \frac{4}{4} = 1\right)$; $Z = \frac{(\bar{Y} - \mu_Y)}{\sqrt{\frac{\sigma_Y^2}{n_Y}}} = (\bar{Y} - \mu_Y) \sim N(0,1)$ y I.C. de 95%

para μ_Y es $\bar{Y} - 1.96 \leq \mu_Y \leq \bar{Y} + 1.96$; dada la m.a. (8, 7, 10, 9), resulta $\bar{Y} = 8.5$ y el I.C. calculado es $8.5 - 1.96 \leq \mu_Y \leq 8.5 + 1.96 \Rightarrow \mathbf{6.54 \leq \mu_Y \leq 10.46}$ con **95% de confianza**.

De los intervalos de confianza, tenemos que el capital de inicio en el sub sector del pintado de automóviles está entre 3.58 y 6.20 miles de dólares mientras que en el sub sector de reparaciones el capital inicial está entre 6.54 y 10.46 miles de dólares, entonces: $\mu_X \leq \mathbf{6.20} < \mathbf{6.54} \leq \mu_Y$ en promedio y con 95% de confianza, podemos decir que, en efecto, es más barato iniciarse en el pintado de automóviles que en la reparación de automóviles.

$$c) f_{XY}(x, y) = f_X(x)f_Y(y) = \frac{e^{-\frac{(x-\mu_X)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \times \frac{e^{-\frac{(y-\mu_Y)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \Rightarrow L(\mu_X, \mu_Y, \sigma^2) = \left(\prod_{j=1}^{n_X} \frac{e^{-\frac{(x_j-\mu_X)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}\right) \left(\prod_{i=1}^{n_Y} \frac{e^{-\frac{(y_i-\mu_Y)^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}\right) =$$

$$\left(\frac{e^{-\sum_{j=1}^{n_X} \frac{(x_j-\mu_X)^2}{2\sigma^2}}}{(\sqrt{2\pi}\sigma)^{n_X}}\right) \left(\frac{e^{-\sum_{i=1}^{n_Y} \frac{(y_i-\mu_Y)^2}{2\sigma^2}}}{(\sqrt{2\pi}\sigma)^{n_Y}}\right) \Rightarrow$$

$$l(\mu_X, \mu_Y, \sigma^2) = -\sum_{j=1}^{n_X} \frac{(X_j - \mu_X)^2}{2\sigma^2} - n_X \ln(\sqrt{2\pi}) - n_X \ln(\sigma) - \sum_{i=1}^{n_Y} \frac{(Y_i - \mu_Y)^2}{2\sigma^2} - n_Y \ln(\sqrt{2\pi}) - n_Y \ln(\sigma)$$

Maximizando $l(\mu_X, \mu_Y, \sigma^2)$:

$$\frac{\partial l(\mu_X, \mu_Y, \sigma^2)}{\partial \mu_X} = -\frac{1}{2\sigma^2} \sum_{j=1}^{n_X} \frac{\partial (X_j - \mu_X)^2}{\partial \mu_X} = 0 \Rightarrow -\frac{1}{2\sigma^2} \sum_{j=1}^{n_X} 2(X_j - \mu_X) \times -1 = 0 \Rightarrow \sum_{j=1}^{n_X} (X_j - \mu_X) = 0 \Rightarrow$$

$$\mu_X = \bar{X} \Rightarrow \hat{\mu}_X = \bar{X}$$

Análogamente $\frac{\partial l(\mu_X, \mu_Y, \sigma^2)}{\partial \mu_Y} = -\frac{1}{2\sigma^2} \sum_{i=1}^{n_Y} \frac{\partial (Y_i - \mu_Y)^2}{\partial \mu_Y} = 0 \Rightarrow \mu_Y = \bar{Y} \Rightarrow \hat{\mu}_Y = \bar{Y}$; finalmente:

$$\frac{\partial l}{\partial \sigma^2} = \frac{\partial}{\partial \sigma^2} \left(-\sum_{j=1}^{n_X} \frac{(X_j - \mu_X)^2}{2\sigma^2} - n_X \ln(\sqrt{2\pi}) - n_X \ln(\sigma) - \sum_{i=1}^{n_Y} \frac{(Y_i - \mu_Y)^2}{2\sigma^2} - n_Y \ln(\sqrt{2\pi}) - n_Y \ln(\sigma) \right) =$$

$$\frac{\partial}{\partial \sigma^2} \left(-\sum_{j=1}^{n_X} \frac{(X_j - \mu_X)^2}{2\sigma^2} - n_X \ln(\sqrt{2\pi}) - \frac{n_X}{2} \ln(\sigma^2) - \sum_{i=1}^{n_Y} \frac{(Y_i - \mu_Y)^2}{2\sigma^2} - n_Y \ln(\sqrt{2\pi}) - \frac{n_Y}{2} \ln(\sigma^2) \right) =$$

$$-\sum_{j=1}^{n_X} \frac{(X_j - \mu_X)^2}{2} \frac{\partial}{\partial \sigma^2} (\sigma^2)^{-1} - \frac{n_X}{2} \frac{\partial}{\partial \sigma^2} \ln(\sigma^2) - \sum_{i=1}^{n_Y} \frac{(Y_i - \mu_Y)^2}{2} \frac{\partial}{\partial \sigma^2} (\sigma^2)^{-1} - \frac{n_Y}{2} \frac{\partial}{\partial \sigma^2} \ln(\sigma^2) =$$

$$\frac{1}{2} \sum_{j=1}^{n_X} (X_j - \mu_X)^2 (\sigma^2)^{-2} - \frac{n_X}{2} \frac{1}{\sigma^2} - \frac{1}{2} \sum_{i=1}^{n_Y} (Y_i - \mu_Y)^2 (\sigma^2)^{-2} - \frac{n_Y}{2} \frac{1}{\sigma^2} = 0 \Rightarrow$$

$$\sum_{j=1}^{n_X} (X_j - \mu_X)^2 (\sigma^2)^{-2} - \frac{n_X}{\sigma^2} - \sum_{i=1}^{n_Y} (Y_i - \mu_Y)^2 (\sigma^2)^{-2} - \frac{n_Y}{\sigma^2} = 0$$

$$\Rightarrow \sum_{j=1}^{n_X} (X_j - \mu_X)^2 - n_X \sigma^2 - \sum_{i=1}^{n_Y} (Y_i - \mu_Y)^2 - n_Y \sigma^2 \Rightarrow \sigma^2 = \frac{\sum_{j=1}^{n_X} (X_j - \mu_X)^2 + \sum_{i=1}^{n_Y} (Y_i - \mu_Y)^2}{n_X + n_Y} \text{ y como } \hat{\mu}_X = \bar{X};$$

$$\hat{\mu}_Y = \bar{Y}, \text{ tenemos } \hat{\sigma}^2 = \frac{\sum_{j=1}^{n_X} (X_j - \bar{X})^2 + \sum_{i=1}^{n_Y} (Y_i - \bar{Y})^2}{n_X + n_Y}.$$

Sobre el insesgamiento: $E(\hat{\sigma}^2) = E\left(\frac{\sum_{j=1}^{n_X}(X_j - \bar{X})^2 + \sum_{i=1}^{n_Y}(Y_i - \bar{Y})^2}{n_X + n_Y}\right) = \frac{1}{n_X + n_Y} E\left(\sum_{j=1}^{n_X}(X_j - \bar{X})^2 + \sum_{i=1}^{n_Y}(Y_i - \bar{Y})^2\right)$

$$= \frac{1}{n_X + n_Y} E((n_X - 1)S_X^2 + (n_Y - 1)S_Y^2) = \frac{1}{n_X + n_Y} \left((n_X - 1) \underbrace{E(S_X^2)}_{\sigma^2} + (n_Y - 1) \underbrace{E(S_Y^2)}_{\sigma^2} \right) = \frac{n_X + n_Y - 2}{n_X + n_Y} \sigma^2$$

$\neq \sigma^2$, es estimador no es insesgado.

Problema 2 (5 puntos)

Sea X con distribución exponencial $X \sim \text{Exp}(x; \beta)$.

- Halle el estimador máximo verosímil de β y use la propiedad de invarianza para hallar el estimador máximo verosímil $\hat{\gamma}$ de $\gamma = \text{Percentil } 25$ de la distribución de X . Recuerde que si k es número entre 0 y 100, el k -ésimo percentil de la distribución de una v.a.c. X es el valor P_k tal que $P(X \leq P_k) = \frac{k}{100}$. (3p.)
- Halle la distribución asintótica del estimador máximo verosímil $\hat{\beta}$ y úsela para hallar el tamaño de muestra que permite que la diferencia $|\hat{\beta} - \beta|$ sea menor al 11% del valor real de β . (2p.)

Solución:

- $X \sim \text{Exp}(x; \beta) \Rightarrow f_X(x; \beta) = \beta e^{-\beta x} \quad x > 0 \Rightarrow L(\beta) = \prod_{i=1}^n \beta e^{-\beta x_i} = \beta^n e^{-\beta \sum_{i=1}^n x_i} = \beta^n e^{-\beta n \bar{X}} \quad \beta > 0$
 $\Rightarrow l(\beta) = \ln(L(\beta)) = n \ln(\beta) - \beta n \bar{X}$ que es función diferenciable; usamos derivadas para maximizar:
 $\frac{\partial l(\beta)}{\partial \beta} = \frac{n}{\beta} - n \bar{X} = 0 \Rightarrow \beta = \frac{1}{\bar{X}}$ y verificando el máximo, tenemos $\hat{\beta} = \frac{1}{\bar{X}}$ es el estimador M.V. de β .

Sea $\gamma = \text{Percentil } 25 \Rightarrow P(X \leq \gamma) = 0.25 \Rightarrow \int_0^\gamma \beta e^{-\beta x} dx = 0.25 \Rightarrow 1 - e^{-\beta \gamma} = 0.25 \Rightarrow e^{-\beta \gamma} = 0.75 \Rightarrow$
 $\beta \gamma = -\ln(0.75) \Rightarrow \gamma = -\frac{\ln(0.75)}{\beta} = h(\beta)$ y por “invarianza” del método de máxima verosimilitud, la relación entre los parámetros γ y β también se reproduce entre los estimadores: $\hat{\gamma} = h(\hat{\beta}) = -\frac{\ln(0.75)}{\hat{\beta}} = -\ln(0.75) \bar{X}$ es el estimador M.V. de $\gamma = \text{Percentil } 25$ de X .

- Sabemos que, bajo las condiciones de regularidad, la distribución asintótica (cuando n es “grande”) el estimador M.V de un parámetro θ tiene distribución $N\left(\theta, \sigma_\theta^2 = \frac{1}{n E\left(\left(\frac{\partial}{\partial \theta} \ln f_X(x; \theta)\right)^2\right)}\right)$. En este caso:

$$\frac{\partial}{\partial \beta} \ln f_X(x; \beta) = \frac{\partial}{\partial \beta} (n \ln(\beta) - \beta n \bar{X}) = \left(\frac{1}{\beta} - \bar{X}\right) \Rightarrow E\left(\left(\frac{\partial}{\partial \beta} \ln f_X(x; \beta)\right)^2\right) = E\left(\left(\frac{1}{\beta} - \bar{X}\right)^2\right) = E\left(\left(\bar{X} - \frac{1}{\beta}\right)^2\right)$$

$$= V(\bar{X}) = \frac{1}{\beta^2} \Rightarrow \sigma_\beta^2 = \frac{1}{n E\left(\left(\frac{\partial}{\partial \beta} \ln f_X(x; \beta)\right)^2\right)} = \frac{\beta^2}{n}, \text{ entonces } n \rightarrow \infty \Rightarrow \hat{\beta} \sim N\left(\beta, \frac{\beta^2}{n}\right)$$

Queremos n tal que $0.95 = P(|\hat{\beta} - \beta| < 0.11\beta) \Rightarrow 0.95 = P(|\hat{\beta} - \beta| < 0.11\beta) = P\left(\frac{|\hat{\beta} - \beta|}{\sqrt{\frac{\beta^2}{n}}} < \frac{0.11\beta}{\sqrt{\frac{\beta^2}{n}}}\right) =$
 $P(|Z| < 0.11\sqrt{n}) \Rightarrow P(Z < 0.11\sqrt{n}) = 0.975 \Rightarrow 0.11\sqrt{n} = 1.96 \Rightarrow n = 17.82^2 = 317.49 \Rightarrow n \cong 318$

Problema 3 (8 puntos)

Sea $Y = \alpha_0 + \beta X + \varepsilon$ un modelo de regresión lineal con intercepto, pero donde el intercepto α_0 es conocido. Dada una m.a. de n parejas $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$, y bajo los supuestos clásicos, se desea estimar el parámetro β .

- Halle el estimador de mínimos cuadrados ordinarios de β y determine si es insesgado. (3p.)
- Si se asume el supuesto adicional $\varepsilon_j \sim N(0, 1)$:
 - Use la función generatriz de momentos y pruebe que $Y_j = \alpha_0 + \beta X_j + \varepsilon_j$ tiene distribución normal, identificando claramente sus parámetros. (1p.)
 - Halle el estimador máximo verosímil de β . (2p.)

(3) ¿Sería consistente el estimador obtenido en (2)? (2p.)

Recuerde que se asume que los $\{X_j\}$ son variables pero no aleatorias. Además, y en general, si R y T son dos variables aleatorias cualesquiera, entonces $V\left(\frac{R}{T}\right) \neq \frac{V(R)}{V(T)}$.

Solución:

a) Para $\hat{\beta}_{MCO}$ el estimador de mínimos cuadrados ordinarios de β : $Q(\beta) = \sum_{j=1}^n (Y_j - \alpha_0 - \beta X_j)^2 \Rightarrow \frac{d}{d\beta} Q(\beta) = 0$

$$\Rightarrow \frac{d}{d\beta} \sum_{j=1}^n (Y_j - \alpha_0 - \beta X_j)^2 = \sum_{j=1}^n \frac{d}{d\beta} (Y_j - \alpha_0 - \beta X_j)^2 = \sum_{j=1}^n 2(Y_j - \alpha_0 - \beta X_j)(-X_j) = 0$$

$$\Rightarrow -2 \sum_{j=1}^n (Y_j X_j - \alpha_0 X_j - \beta X_j^2) = 0 \Rightarrow \sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j - \beta \sum_{j=1}^n X_j^2 = 0 \Rightarrow \beta = \frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2} \text{ y}$$

$$\text{asumiendo el mínimo, tenemos } \hat{\beta} = \frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2}.$$

$$E(\hat{\beta}) = E\left(\frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2}\right) \stackrel{X_j \text{ no aleat.}}{=} \frac{1}{\sum_{j=1}^n X_j^2} E\left(\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j\right) \stackrel{X_j \text{ no aleat.}}{=} \frac{1}{\sum_{j=1}^n X_j^2} (\sum_{j=1}^n X_j E(Y_j) - \alpha_0 \sum_{j=1}^n X_j)$$

$$= \frac{1}{\sum_{j=1}^n X_j^2} (\sum_{j=1}^n X_j E(Y_j) - \alpha_0 \sum_{j=1}^n X_j) = \frac{1}{\sum_{j=1}^n X_j^2} (\sum_{j=1}^n X_j (\alpha_0 + \beta X_j) - \alpha_0 \sum_{j=1}^n X_j), \text{ pues}$$

$$E(Y_j) = E(\alpha_0 + \beta X_j + \varepsilon_j) = \alpha_0 + \beta X_j + E(\varepsilon_j) = \alpha_0 + \beta X_j, \text{ ya que } E(\varepsilon_j) = 0 \Rightarrow$$

$$E(\hat{\beta}) = \frac{1}{\sum_{j=1}^n X_j^2} (\alpha_0 \sum_{j=1}^n X_j + \beta \sum_{j=1}^n X_j^2 - \alpha_0 \sum_{j=1}^n X_j) = \beta, \text{ el estimador M.C.O es insesgado.}$$

b) Si $\varepsilon_j \sim N(0,1)$ entonces:

$$(1) \varepsilon_j \sim N(0, \sigma^2 = 1) \forall j \Rightarrow M_{Y_j}(t) = E(e^{tY_j}) = E(e^{t(\alpha_0 + \beta X_j + \varepsilon_j)}) = E(e^{t(\alpha_0 + \beta X_j)} e^{t\varepsilon_j}) = e^{t(\alpha_0 + \beta X_j)} M_{\varepsilon_j}(t)$$

$$\text{y como en general, si } W \sim N(\mu, \sigma^2) \Rightarrow M_W(t) = E(e^{tW}) = e^{t\mu + \frac{t^2}{2}\sigma^2} \Rightarrow M_{\varepsilon_j}(t) = e^{t \cdot 0 + \frac{t^2}{2} \cdot 1} = e^{\frac{t^2}{2}}. \text{ así}$$

$$M_{Y_j}(t) = e^{t(\alpha_0 + \beta X_j)} e^{\frac{t^2}{2}} = e^{t(\alpha_0 + \beta X_j) + \frac{t^2}{2}} \text{ que corresponde a la función generatriz de momentos de una distribución normal } N(\alpha_0 + \beta X_j, 1), \text{ es decir } Y_j \sim N(\alpha_0 + \beta X_j, 1).$$

$$(2) Y_j \sim N(\alpha_0 + \beta X_j, \sigma^2 = 1) \Rightarrow f_{Y_j}(Y_j; \mu_j = \alpha_0 + \beta X_j) = \frac{e^{-\frac{(Y_j - \alpha_0 - \beta X_j)^2}{2}}}{\sqrt{2\pi}} \Rightarrow L(\beta) = \prod_{j=1}^n f_{Y_j}(Y_j; \beta) \text{ y la log-verosimilitud es:}$$

$$l(\beta) = \ln(L(\beta)) = \sum_{j=1}^n \ln f_{Y_j}(Y_j; \beta) = \sum_{j=1}^n \ln \left(\frac{e^{-\frac{(Y_j - \alpha_0 - \beta X_j)^2}{2}}}{\sqrt{2\pi}} \right) = \sum_{j=1}^n \left(-\frac{(Y_j - \alpha_0 - \beta X_j)^2}{2} - \ln(\sqrt{2\pi}) \right) =$$

$$\frac{1}{2} \sum_{j=1}^n (Y_j - \alpha_0 - \beta X_j)^2 - n \ln(\sqrt{2\pi}) \Rightarrow \frac{dl(\beta)}{d\beta} = 0 \Rightarrow \frac{d}{d\beta} \sum_{j=1}^n (Y_j - \alpha_0 - \beta X_j)^2 = 0 \text{ que es la misma ecuación}$$

$$\text{del estimador M.C.O. de modo que } \hat{\beta} = \frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2} \text{ es también el estimador M.V.}$$

$$(3) \hat{\beta} = \frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2} \text{ ya es insesgado (según lo visto en a), por tanto es asintóticamente insesgado:}$$

$$E(\hat{\beta}) = \beta \Rightarrow \lim_{n \rightarrow \infty} E(\hat{\beta}) = \beta \text{ (insesgamiento asintótico).}$$

$$V(\hat{\beta}) = V\left(\frac{\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j}{\sum_{j=1}^n X_j^2}\right) \stackrel{X_j \text{ no aleat.}}{=} \frac{1}{(\sum_{j=1}^n X_j^2)^2} V\left(\sum_{j=1}^n Y_j X_j - \alpha_0 \sum_{j=1}^n X_j\right) \stackrel{\text{no aleat.}}{=}$$

$$= \frac{1}{(\sum_{j=1}^n X_j^2)^2} V(\sum_{j=1}^n Y_j X_j) = \frac{1}{(\sum_{j=1}^n X_j^2)^2} \sum_{j=1}^n X_j^2 V(Y_j) \text{ y } V(Y_j) = V\left(\alpha_0 + \beta X_j + \varepsilon_j\right) \stackrel{\text{no aleat.}}{=} V(\varepsilon_j) = 1 \Rightarrow$$

$$V(\hat{\beta}) = \frac{1}{(\sum_{j=1}^n X_j^2)^2} \sum_{j=1}^n X_j^2 = \frac{1}{\sum_{j=1}^n X_j^2} \Rightarrow \lim_{n \rightarrow \infty} V(\hat{\beta}) = \lim_{n \rightarrow \infty} \left(\frac{1}{\sum_{j=1}^n X_j^2} \right) = 0 \text{ si, como es usual, } X_j \text{ toma valores}$$

“grandes” de modo que $\sum_{j=1}^{\infty} X_j^2 = \infty$, esto es : $\lim_{n \rightarrow \infty} V(\hat{\beta}) = \mathbf{0}$ de modo que $\hat{\beta}$ es “asintóticamente eficiente”

Al cumplir $\hat{\beta}$ las dos condiciones, insesgamiento asintótico y eficiencia asintótica, $\hat{\beta}$ es estimador consistente del parámetro β .

01 de diciembre de 2018.

ACG./SAMP.

NO USAR EN EVALUACIONES