

**PRÁCTICA CALIFICADA 5**

**CURSO:** EST 241 Estadística Inferencial. **HORARIO:** 0621. **PROFESOR:** Arturo Calderón G.

**FECHA:** 22 de junio de 2019. **SEMESTRE:** 2019-1. **DURACIÓN DE LA PRUEBA:** 2 horas.

Salvo formulario y calculadora, no está permitido el uso de otro material de consulta durante el desarrollo de la prueba, ni el uso de otros dispositivos electrónicos (celulares, tablets, laptops, iPods, etc.). Cualquier material relativo al curso, así como celulares y dispositivos electrónicos, deben permanecer guardados durante la prueba.

**Problema 1 (8 puntos)**

- a) Si  $X \sim N(0,2)$  e  $Y \sim N(0,4)$  son independientes, halle valores  $a$  y  $c$  tal que  $P(aX^2 + Y^2 \leq c) = 0.95$  (2p.)
- b) Si  $X \sim N(0, \sigma^2)$  e  $Y \sim N(0, \sigma^2)$  son independientes, use la función generatriz de momentos y pruebe que  $D = (X - Y)$  tiene distribución normal. Si definimos  $U = c(X - Y)^2$ , halle  $c$  tal que  $U$  tenga distribución  $\chi^2(k)$  e indique el valor de  $k$  (2p.)
- c) Si  $X \sim N(0,16)$  y se toma una m.a. de tamaño 12. Halle  $b$  de modo que  $F = b \frac{\sum_{j=1}^4 X_j^2}{S^2}$  tenga distribución  $F$  de Fisher, si la primera sumatoria se hace sobre las 4 primeras observaciones y  $S^2$  es la varianza del resto. (2p.)
- d) Si  $X \sim N(0,16)$  y se toma una m.a. de tamaño 12, halle  $c$  tal que  $U = c\bar{X}/S$  tenga distribución t-Student. (2p.)

**Solución:**

- a) Estandarizando primero, tenemos:  $Z_1 = X/\sqrt{2} \sim N(0, 1)$  y  $Z_2 = Y/2 \sim N(0,1)$ . Sean ahora,  $W_1 := Z_1^2 = X^2/2$  y  $W_2 := Z_2^2 = Y^2/4$ . Se deduce que  $W_1 \sim \chi^2(1)$  y que  $W_2 \sim \chi^2(1)$  también. Por tanto, con toda seguridad,  $(W_1 + W_2) = (X^2/2) + (Y^2/4) \sim \chi^2(2)$ . Aplicando lo anterior a los datos:  
**0.95 =  $P(aX^2 + Y^2 \leq c) = P((aX^2/4) + (Y^2/4)) \leq c/4 = P(\frac{a}{2}W_1 + W_2 \leq c/4)$ .** Si tomamos  $a = 2$  llegamos a **0.95 =  $P(W_1 + W_2 \leq c/4)$**  y de la tabla Ji-Cuadrado, con  $k = 2$  grados de libertad, tenemos  $c/4 = \chi_{0.95}^2 = 5.99$ . Por tanto  $a = 2$  y  $c = 4 \times 5.99 = 23.96$  es la respuesta.
- b)  $M_D(t) = E(e^{tD}) = E(e^{t(X-Y)}) = E(e^{tX} \times e^{-tY}) \stackrel{(1)}{=} E(e^{tX}) \times E(e^{-tY}) = M_X(t) \times M_Y(-t) \stackrel{(2)}{=} \left( e^{t0 + \frac{t^2}{2}\sigma^2} \right) \left( e^{t(-0) + \frac{t^2}{2}\sigma^2} \right) = \left( e^{t0 + \frac{t^2}{2}(2\sigma^2)} \right) \Rightarrow M_D(t) = e^{t0 + \frac{t^2}{2}(2\sigma^2)}$  corresponde a la F.G.M. de una distribución  $N(0, 2\sigma^2) \Rightarrow D \sim N(0, 2\sigma^2)$
- (1)  $X$  e  $Y$  son independientes; (2)  $\forall v.a. W: W \sim N(\mu, \sigma^2) \Leftrightarrow M_W(l) = e^{l\mu + \frac{l^2}{2}\sigma^2}$
- c)  $X \sim N(\mu = 0, \sigma^2 = 16)$ ;  $n = 12$  y  $F = b \frac{\sum_{j=1}^4 X_j^2}{S^2}$ . Para que sea una variable  $F$  debe ser el cociente de dos  $\chi^2$  divididas entre sus grados de libertad, demos a  $F$  ese tipo de estructura:  
 $Z_j = \frac{X_j}{4} \sim N(0,1) \Rightarrow Z_j^2 = \frac{X_j^2}{16} \sim \chi^2(k=1)$  y sumando:  $\sum_{j=1}^4 \left( \frac{X_j^2}{16} \right) = \left( \frac{\sum_{j=1}^4 X_j^2}{16} \right) \sim \chi^2(k=4)$ .  
 $S^2$  es la varianza de las  $n - 4 = (12 - 4) = 8$  observaciones restantes  $\Rightarrow W = \frac{(8-1)S^2}{\sigma^2} = \frac{7S^2}{16} \sim \chi^2(k=7)$ .  
Con toda seguridad  $F = \frac{\left( \frac{\sum_{j=1}^4 X_j^2}{16} \right)}{\frac{7S^2}{16}} = \frac{\frac{1}{16}(\sum_{j=1}^4 X_j^2)}{\frac{7S^2}{16}} = \frac{1}{4} \left( \frac{\sum_{j=1}^4 X_j^2}{S^2} \right) \sim F(k_1 = 4, k_2 = 7)$  y comparando con  $b \frac{\sum_{j=1}^4 X_j^2}{S^2}$  se tiene que  $b = \frac{1}{4}$ .
- d) Si  $X \sim N(\mu = 0, \sigma^2 = 16)$ ;  $n = 12$  y sabemos por teoría que en general, para una m.a. de tamaño  $n$   $t := \frac{(\bar{X} - \mu)}{\frac{s}{\sqrt{n}}} \sim t(k = n - 1)$  que en este caso es  $t := \frac{\bar{X}}{\frac{s}{\sqrt{12}}} \sim t(k = 11)$  y comparando con  $U = c\bar{X}/S$  vemos que  $c = \sqrt{12}$  es la constante que hace que  $U = c\bar{X}/S$  tenga distribución t-Student.

**Problema 2 (12 puntos)**

- a) Si  $X \sim U(x; \theta - p, \theta + p)$ , halle los estimadores de momentos de  $\theta$  y  $p$ . ¿Es insesgado  $\hat{\theta}$ ? Estudie la consistencia de  $\hat{\theta}$  y  $\hat{p}$ . (4p.)
- b) Sea  $X \sim N(0, \sigma^2)$ , halle el estimador de momentos de  $\sigma^2$  y compárelo con  $S^2$  como estimador de  $\sigma^2$  en cuanto a insesgamiento y eficiencia. Recuerde que en el muestreo de una distribución normal  $S^2 \sim \Gamma(\alpha = \frac{n-1}{2}, \beta = \frac{2\sigma^2}{n-1})$  y que en general  $Z^2 = \frac{(X-\mu)^2}{\sigma^2} \sim \chi^2(1)$ . (4p.)
- c) En un modelo econométrico se escribe el consumo mensual  $C_i$  de la  $i$ -ésima familia de una muestra aleatoria de  $n$  familias, como función de su ingreso mensual disponible  $y_i$ , que es dado y fijo, en un modelo de datos de la forma  $C_i \sim N(\beta_1 y_i, \sigma^2 = y_i)$ ;  $\beta_1 > 0$ , generando la m.a. de  $n$  parejas  $(C_1, y_1), (C_2, y_2), \dots, (C_n, y_n)$ . En este contexto, halle el MELI del parámetro  $\beta_1$  y compárelo con otro estimador de  $\beta_1$  dado por  $\tilde{\beta}_1 = \frac{C_n - C_1}{y_n - y_1}$ . (4p.)

**Solución:**

- a)  $X \sim U(x; \theta - p, \theta + p)$ , son dos parámetros por estimar, necesitamos dos ecuaciones. Empezamos con los dos primeros momentos poblacionales. Como se trata de una distribución uniforme  $U(x; \alpha = \theta - p, \beta = \theta + p)$ , podemos escribir las ecuaciones estructurales:

$$m_1 = E(X) = \frac{(\theta - p) + (\theta + p)}{2} = \theta$$

$$m_2 = E(X^2) = \sigma^2 + (\mu)^2 = \frac{((\theta + p) - (\theta - p))^2}{12} + \theta^2 = \frac{(2p)^2}{12} + \theta^2 = \frac{p^2}{3} + \theta^2$$

$$\begin{cases} m_1 = E(X) = \theta \\ m_2 = E(X^2) = \frac{p^2}{3} + \theta^2 \end{cases}$$

Pasamos a las ecuaciones de estimación reemplazando parámetros por estimadores, donde  $\hat{m}_1 = M_1 = \bar{X}$  y

$$\hat{m}_2 = M_2 = \frac{\sum_{j=1}^n X_j^2}{n}.$$

$$\begin{cases} \hat{m}_1 = M_1 \\ \hat{m}_2 = M_2 \end{cases} \Rightarrow \begin{cases} \bar{X} = \hat{\theta} \\ \frac{\sum_{j=1}^n X_j^2}{n} = \frac{\hat{p}^2}{3} + \hat{\theta}^2 \end{cases} \text{ Resolviendo el sistema tenemos los estimadores de momentos:}$$

$$\hat{\theta} = \bar{X} \text{ y } \hat{p} = \sqrt{3 \left( \frac{\sum_{j=1}^n X_j^2}{n} - \bar{X}^2 \right)} = \sqrt{3 \left( \frac{\sum_{j=1}^n X_j^2}{n} - \bar{X}^2 \right)}$$

**Inssegadez** de  $\hat{\theta}$ :  $E(\hat{\theta}) = E(\bar{X}) = \mu = \theta$ ; en efecto  $\hat{\theta}$  es estimador insesgado de  $\theta$ .

**Consistencia** de  $\hat{\theta}$  y  $\hat{p}$ : Aquí es más práctico usar el operador Límite en probabilidad  $Plim$  y el Teorema de Slutsky, recordando además que, en general,  $Plim(M_k) = m_k = E(X^k)$ , según se vió en la teoría del curso:

$$Plim(\hat{\theta}) = Plim(\bar{X}) = \mu = \theta \Rightarrow \hat{\theta} \text{ es estimador consistente de } \theta.$$

$$Plim(\hat{p}) = Plim \sqrt{3 \left( \frac{\sum_{j=1}^n X_j^2}{n} - \bar{X}^2 \right)} = \sqrt{3 \left( Plim \left( \frac{\sum_{j=1}^n X_j^2}{n} \right) - Plim(\bar{X}^2) \right)} = \sqrt{3(Plim(M_2) - Plim(\bar{X})^2)} =$$

$$\sqrt{3(m_2 - (Plim \bar{X})^2)} = \sqrt{3(m_2 - \theta^2)} = \sqrt{3 \left( \frac{p^2}{3} + \theta^2 - \theta^2 \right)} = \sqrt{3 \left( \frac{p^2}{3} \right)} = p \Rightarrow \hat{p} \text{ es estimador consistente de } p$$

- b)  $X \sim N(0, \sigma^2) \Rightarrow m_1 = E(X) = 0$ , esta ecuación no sirve, pasamos a  $m_2 = E(X^2) = \sigma^2 + (\mu)^2 = \sigma^2$  que sí es útil  $\hat{m}_2 = M_2 = \frac{\sum_{j=1}^n X_j^2}{n} = \hat{\sigma}^2 \Rightarrow \hat{\sigma}^2 = \frac{\sum_{j=1}^n X_j^2}{n}$  es el estimador de momentos buscado.

Pasamos a comparar con  $S^2$ , del cual ya sabemos, por la teoría del curso, que  $E(S^2) = \sigma^2$  y  $V(S^2) = \frac{2\sigma^2}{n-1}$

$E(\widehat{\sigma^2}) = E\left(\frac{\sum_{j=1}^n X_j^2}{n}\right) = \left(\frac{1}{n}\right) E(\sum_{j=1}^n X_j^2) = \left(\frac{1}{n}\right) (\sum_{j=1}^n E(X_j^2)) = \left(\frac{1}{n}\right) \sum_{j=1}^n \sigma^2 = \left(\frac{1}{n}\right) n\sigma^2 = \sigma^2$ . El estimador de momentos también es insesgado. Pasamos a estudiar la eficiencia, comparando varianzas:

$$V(\widehat{\sigma^2}) = V\left(\frac{\sum_{j=1}^n X_j^2}{n}\right) = \left(\frac{1}{n^2}\right) V\left(\sum_{j=1}^n X_j^2\right) = \left(\frac{1}{n^2}\right) \left(\sum_{j=1}^n V(X_j^2)\right) = \left(\frac{1}{n^2}\right) \sum_{j=1}^n V(X^2) = \left(\frac{1}{n^2}\right) nV(X^2) = \frac{V(X^2)}{n}$$

Falta hallar  $V(X^2)$ . Para ello aplicaremos la distribución Chi<sup>2</sup>:

$X \sim N(0, \sigma^2) \Rightarrow Z = \frac{X}{\sigma} \sim N(0, 1) \Rightarrow Z^2 = \frac{X^2}{\sigma^2} \sim \chi^2(k = 1)$ . Por teoría sabemos que  $\chi^2(k)$  es un caso particular de la distribución Gamma, esto es,  $\chi^2(k) \equiv \Gamma\left(w; \alpha = \frac{k}{2}, \beta = 2\right) \Rightarrow E(W) = k, V(W) = 2k$  y en este caso  $k = 1$  de modo que  $V(Z^2) = 2$  y como  $Z^2 = \frac{X^2}{\sigma^2} \Rightarrow 2 = V(Z^2) = V\left(\frac{X^2}{\sigma^2}\right) = \frac{1}{\sigma^4} V(X^2) \Rightarrow V(X^2) = 2\sigma^4 \Rightarrow V(\widehat{\sigma^2}) = \frac{2\sigma^4}{n}$ .

Regresando a la eficiencia:

$V(\widehat{\sigma^2}) = \frac{2\sigma^4}{n} < \frac{2\sigma^2}{n-1} = V(S^2)$ , de modo que el estimador de momentos  $\widehat{\sigma^2} = \frac{\sum_{j=1}^n X_j^2}{n}$ , en este caso, es más eficiente que  $S^2$  como estimador de  $\sigma^2$ .

- c) La muestra de  $n$  observaciones es una muestra de  $n$  parejas donde los ingresos  $y_i$  no son aleatorios  $(C_1, y_1), (C_2, y_2), \dots, (C_n, y_n)$  pero los consumos  $C_i \sim N(\beta_1 y_i, \sigma^2 = y_i)$  sí lo son, siendo v.a. independientes aunque ya no con distribución idéntica, en particular del dato  $C_i \sim N(\beta_1 y_i, \sigma^2 = y_i)$  se tiene que  $E(C_i) = \beta_1 y_i$  y también que  $V(C_i) = y_i$ .

Sea  $\widehat{\beta}_1$  el tal MELI de  $\beta_1$ , entonces:

- (1)  $\widehat{\beta}_1$  debe ser función lineal de la muestra (en verdad, función de la “parte aleatoria”  $C_i$  de la muestra de parejas  $(C_i, y_i)$ )  $\Rightarrow \widehat{\beta}_1 = \sum_{i=1}^n \alpha_i C_i$  donde los coeficientes  $\alpha_1, \alpha_2, \dots, \alpha_n$  son las incógnitas por hallar.
- (2)  $\widehat{\beta}_1$  debe ser estimador *insesgado* del parámetro  $\Rightarrow E(\widehat{\beta}_1) = \beta_1 \Rightarrow E(\sum_{i=1}^n \alpha_i C_i) = \sum_{i=1}^n \alpha_i E(C_i) = \sum_{i=1}^n \alpha_i \beta_1 y_i = \beta_1 \sum_{i=1}^n \alpha_i y_i = \beta_1 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 1$  es la restricción con “condición de insesgamiento” que deben satisfacer los coeficientes  $\alpha_1, \alpha_2, \dots, \alpha_n$  del MELI.
- (3)  $\widehat{\beta}_1$  debe ser más eficiente que cualquier otro estimador que sea *lineal e insesgado*, o sea que debe tener varianza mínima dentro del conjunto de estimadores *lineales e insesgados*. Esto se consigue tomando los coeficientes  $\alpha_1, \alpha_2, \dots, \alpha_n$  de modo que minimicen  $V(\sum_{i=1}^n \alpha_i C_i)$  sujetos a la restricción  $\sum_{i=1}^n \alpha_i y_i = 1$ .

Como  $V(\sum_{i=1}^n \alpha_i C_i) = \sum_{i=1}^n \alpha_i^2 V(C_i) = \sum_{i=1}^n \alpha_i^2 y_i$ , entonces la función objetivo (por minimizar) genera el problema:

Mín  $\sum_{i=1}^n \alpha_i^2 y_i$  s.a.  $\sum_{i=1}^n \alpha_i y_i = 1$ ; que se puede resolver aplicando Lagrange:

$$L(\alpha_1, \alpha_2, \dots, \alpha_n, \lambda) = \sum_{i=1}^n \alpha_i^2 y_i + \lambda(1 - \sum_{i=1}^n \alpha_i y_i) \Rightarrow \begin{cases} \frac{\partial L}{\partial \alpha_k} = 2\alpha_k y_k - \lambda y_k = 0 \\ \frac{\partial L}{\partial \lambda} = 1 - \sum_{i=1}^n \alpha_i y_i = 0 \end{cases} \text{ y resolviendo estas}$$

$(n+1)$  ecuaciones:

$$2\alpha_k y_k - \lambda y_k = 0 \Rightarrow \alpha_k = \frac{\lambda}{2} \quad k = 1, 2, \dots, n \text{ y en la última ecuación}$$

$$1 - \sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 1 \Rightarrow \sum_{i=1}^n \frac{\lambda}{2} y_i = 1 \Rightarrow \frac{\lambda}{2} \sum_{i=1}^n y_i = 1 \Rightarrow \lambda = \frac{2}{\sum_{i=1}^n y_i} \Rightarrow \alpha_i = \frac{\lambda}{2} = \frac{1}{\sum_{i=1}^n y_i} \text{ y}$$

$$\text{resulta } \widehat{\beta}_{1MELI} = \sum_{i=1}^n \left(\frac{1}{\sum_{i=1}^n y_i}\right) C_i = \left(\frac{1}{\sum_{i=1}^n y_i}\right) \sum_{i=1}^n C_i = \frac{\sum_{i=1}^n C_i}{\sum_{i=1}^n y_i}.$$

Para comparar con  $\widetilde{\beta}_1 = \frac{C_n - C_1}{y_n - y_1}$ , primero veamos el insesgamiento:  $\widehat{\beta}_{1MELI} = \frac{\sum_{i=1}^n C_i}{\sum_{i=1}^n y_i}$  es insesgado por construcción;

$E(\widetilde{\beta}_1) = E\left(\frac{C_n - C_1}{y_n - y_1}\right) = \frac{1}{y_n - y_1} E(C_n - C_1) = \frac{1}{y_n - y_1} (\beta_1 y_n - \beta_1 y_1) = \beta_1$ , pues según el enunciado, el ingreso  $y_i$  es dado y fijo para cada familia y  $E(C_i) = \beta_1 y_i$ , o sea  $\widetilde{\beta}_1$  también es insesgado. Como ambos estimadores

son insesgados, pasamos a estudiar la eficiencia, o sea a comparar varianzas. Como  $\widetilde{\beta}_1 = \frac{c_n - c_1}{y_n - y_1}$  también es estimador lineal, pues  $\widetilde{\beta}_1 = \left(\frac{1}{y_n - y_1}\right) c_n - \left(\frac{1}{y_n - y_1}\right) c_1$ , y es insesgado según ya probamos, entonces, por construcción, tiene mayor varianza que  $\widehat{\beta}_{1_{MELI}}$ . Por tanto  $\widehat{\beta}_{1_{MELI}}$  es más eficiente, es mejor estimador.

NO USAR EN LAS EVALUACIONES